
作业 5：推理

人工智能基础

介绍

本次作业需要提交说明文档（PDF 形式）和 Python 的源代码。注意事项如下：

- 本次作业满分为 100 分。
- 除简答题、编程题外的题目，请给出必要的解答过程，只有答案且过于简略的回答会酌情扣除一定分数。题目要求直接回答或只汇报结果的题目，则不需要给出过程或分析。
- **请不要使用他人的作业，也不要向他人公开自己的作业，复制网上内容须在报告中说明**，否则将受到严厉处罚，作业分数扣至-100（即倒扣本次作业的全部分值）。
- 完成作业过程中，如果使用了大模型辅助（如润色文笔、询问知识点等），请在作业末尾声明使用的方式和程度（不影响作业评分）。**禁止直接粘贴大模型输出的文本**，否则会扣除一定的作业分数。
- 统一文件的命名：{学号}_{姓名}_hw5.zip。所有解答和实验报告请写在一个 pdf 文件中，和代码一起压缩上传。

1 简答题（20 分）

1. 请简述最大似然估计（MLE）与最大后验估计（MAP）之间的主要区别。进一步地，若对模型参数 θ 施加零均值各向同性高斯先验

$$p(\theta) \propto \exp(-\lambda \|\theta\|_2^2),$$


请说明此时 MAP 估计与在损失函数中加入 L_2 正则化项之间的关系，并解释当数据量非常大时 MLE 与 MAP 的关系。

2. 在 LDA 的生成模型中，为什么要分别为每个文档引入一个主题分布（Dirichlet 分布），而不是为整个语料库引入一个共享的主题分布？这样设计的统计意义与表达能力体现在哪里？
3. 变分自编码器（VAE）通过引入一个“推断网络”来近似潜在变量的后验分布。请解释为何在优化过程中不能直接最大化似然，而是要使用变分下界，并指出“重参数化技巧”解决了什么具体问题。

2 解答题

2.1 朴素贝叶斯网络 (15 分)

考虑如下朴素贝叶斯网络：



其中类别 C 是取值 $\{1, 2, \dots, K\}$ 的离散随机变量，满足多项分布 $p(C = c) = \Theta_{C=c}$ ；特征 $\mathbf{X} = X_1 \dots X_N$ 是 N 个取值 $\{0, 1\}$ 的离散变量，满足伯努利分布

$$p(X_i = 1 \mid C = c) = \Phi_{X_i=1|c}.$$

- (a) **(最大似然估计)** 有 M 个独立同分布的样本 $D = \{(c_i, \mathbf{x}_i)\}_{i=1}^M$ ，请写出参数 $\Theta_C, \Phi_{X_i|C}$ 的最大似然估计。

(提示：你可以假设样本足够多，答案中可能出现的计数均不为 0，下同)

- (b) **(最大后验估计)** Dirichlet 分布定义如下：

$$p(\Theta) = \frac{1}{Z} \prod_k \Theta_k^{\alpha_k - 1} \quad \text{where} \quad Z = \frac{\prod_{i=1}^k \Gamma(\alpha_i)}{\Gamma(\sum_{i=1}^k \alpha_i)}, \quad \Gamma(x) = \int_0^\infty t^{x-1} e^{-t} dt$$

对 $\Theta_C, \Phi_{X_i|C=c}$ 分别施加 Dirichlet 先验，分布参数分别为 α_C 和 $\alpha_{x_i|c}$ ，请计算收集到题目定义的样本集 D 之后，参数 $\Theta_C, \Phi_{X_i|c}$ 的最大后验估计。

(提示：答案中不应出现导数和积分项)

- (c) **(EM 算法)** 在现实应用中，类别变量 C 往往是隐藏的，即 $D = \{\mathbf{x}_i\}_{i=1}^M$ ，因此需要运用 EM 算法学习该模型的参数。请通过以下步骤证明：如果将参数初始化为均匀分布：

$$\Theta_{C=c}^{(0)} = \frac{1}{K}, \quad \Phi_{X_i=1|c}^{(0)} = \frac{1}{2},$$

那么 EM 算法将经过一次迭代之后就收敛。


- (a) 请计算 E 步中得到的最优的证据下界 (ELBO) $J(\Theta_C, \Phi_{X_i|c})$ 的表达式

- (b) 请计算经过一次 EM 迭代之后的参数值 $\Theta_C^{(1)}, \Phi_{X_i|c}^{(1)}$

- (c) 请计算经过两次 EM 迭代之后的参数值 $\Theta_C^{(2)}, \Phi_{X_i|c}^{(2)}$

2.2 变分自编码器 (Variational Auto-Encoder, VAE, 15 分)

变分自编码器 (VAE) 是一种基于变分推断实现的深度生成模型，其模型框架如下图所示：




VAE 假设样本 x 由隐变量 z 通过解码器网络 $p_\theta(x|z)$ 表示的分布决定，其中 $p(z) = \mathcal{N}(0, \mathbf{I})$ ，并设计编码器网络 $q_\phi(z|x)$ 进行变分推断训练，优化如下的损失函数：

$$\mathcal{L}_{\text{ELBO}}(x; \phi, \theta) = \mathbb{E}_{z \sim q_\phi(z|x)} [-\log p_\theta(x|z)] + \text{KL}(q_\phi(z|x) \| p(z))$$

现将 VAE 扩展为条件生成模型，即 Conditional VAE (CVAE)，例如生成指定数字的手写数字图像。在 CVAE 中，样本 x 和隐变量 $z \sim \mathcal{N}(0, \mathbf{I})$ 和给定的条件变量 c （例如要生成的数字）共同决定，对应条件解码器网络 $p_\theta(x|z, c)$ ，并假设 c 与 z 独立。考虑模型的推理和训练过程：

- 画出 x, z, c, x 的概率图模型，并用 $p(z)$ 和 $p_\theta(x|z, c)$ 表示 $p(x|c)$ 。
- 为进行变分推断，需要设计编码器网络近似隐变量 z 的条件分布。注意到 c 与 z 独立，但在给定 x 的情况下，编码器建模的是 $q_\phi(z|x, c)$ 而不是 $q_\phi(z|x)$ ，请从变量条件独立的角度解释原因。
- 根据 VAE 的损失函数，直接写出 CVAE 的损失函数 $\mathcal{L}_{\text{ELBO}}(x, c; \phi, \theta)$ 。提示： c 在概率分布中以条件的形式出现。
- 在 $p_\theta(x|z, c)$ 和 $q_\phi(z|x, c)$ 的建模中，若 $x \in \mathbb{R}^d$ ， $z \in \mathbb{R}^{d'}$ 是一维向量， $c \in \{1, 2, \dots, k\}$ 是类别标签，请写出合适的将 c 加到网络输入的方式。
- 若 x 是与图像对应的图像，则解码器通常使用 U-Net 作为网络架构，如下图所示（有关 z 的部分在此省略），其中每个立方体代表一个特征图（Feature Map），立方体的高、宽、厚分别代表特征图的高、宽和通道（Channel）数。图中所简略代表 U-Net 的特殊设计：它将浅层与深层的特征图在通道上进行拼接，并作为下一隐藏层的输入。例如，图中 x_4 的计算为 $\mathbf{x}_4 = F([\mathbf{x}_1, \mathbf{x}_3])$ ，其中中括号为对应隐藏层，方括号代表拼接操作。此种设计有什么好处？



3 图像生成: Diffusion Models (30 分)

问题背景 本编程作业旨在让同学们深入理解生成模型，特别是扩散模型 (Diffusion Models)，并应用于手写数字生成任务。在这次任务中，我们将依次完成多个步骤，包括前向加噪、模型训练、反向采样、推理生成、可视化以及模型评估。

任务目标 本编程作业的目标是让学生掌握扩散模型的核心概念与应用。学生需要理解扩散模型的前向加噪过程、基于 U-Net 的反向去噪模型、扩散模型的训练目标以及采样过程。随后，学生需要进一步理解条件扩散模型 (Conditional Diffusion Model)，特别是类别标签如何注入模型结构，使模型能够生成指定类别的手写数字图像。最后，学生将通过运行测评代码，对生成效果进行分析与评价，从而深入理解扩散模型在图像生成任务中的应用和性能表现。

1. **走进扩散模型**: 扩散模型 (Diffusion Models) 是现代生成模型中的重要组成部分。在此, 我们提供了一份完整的基于 U-Net 架构的扩散模型的训练、推理、可视化流程的代码。请你阅读 `unified_model/models/diffusion_model.py` 与 `samplers/diffusion_samplers.py`, 补全 `diffusion_samplers.py` 中的 `sample_forward` 函数。
2. **扩散模型的训练与推理**: 请参考 `README.md` 的脚本, 依次完成扩散模型 (Diffusion Model) 的训练、推理与可视化。在你的报告中, 请包括 `out/samples/diffusion_ddpm_samples.png` 与 `out/visualization/diffusion_ddpm_visualization/denoising_grid.png`。图像示例如下:




图 1: 例: `denoising_grid.png`

3. **为扩散模型加入条件**: 那么聪明的小朋友就会说了: “嗯? 这个扩散模型并没有接收数字条件作为输入, 那它生成的东西我也不知道是什么数字呀”, 这非常有道理。因此, 我们可以参考条件生成模型的思想, 得到条件扩散模型 (Conditional Diffusion Models)。在这里, 一个核心的问题在于将数字条件加入模型的架构。请阅读 `unified_model/models/unet.py`, 补全 `ConditionalUNet` 类 `forward` 函数中条件注入的部分。
4. **条件扩散模型的训练与推理**: 请参考 `README.md` 的脚本, 依次完成条件扩散模型 (Conditional Diffusion Model) 的训练、推理、可视化与评测。请在你的报告中包括推理得到的网格、去噪过程可视化的图像、以及评测得到的每一类的 FID Score。

参数选择 完成上述题目时, 可以自由选择适合你的情况的参数进行训练, 但过于不合理的参数设置可能会导致扣分 (若报告未说明实验使用的参数, 则会以提交的代码为准)。

4 文生图扩散模型 (20 分)

问题背景 前面的手写数字生成任务关注的是在小规模数据集上训练和理解生成模型。本题进一步走进现代文生图 (Text-to-Image, T2I) 扩散模型的推理过程。扩散模型的基本思想是先逐步向真实图像加入高斯噪声, 再训练神经网络学习反向去噪过程, 从而可以从随机噪声生成图像 [1]。Stable Diffusion 属于 latent diffusion model: 它不直接在像素空间中去噪, 而是先通过 VAE 将图像压缩到低维 latent 空间, 在 latent 空间中用带有 cross-attention 的 UNet 接收文本条件并迭代去噪, 最后再由 VAE 解码回图像 [2]。这种设计显著降低了推理和训练成本, 也使得文本条件生成可以在较小的显存和算力预算下运行。

本作业提供了一个小型 Stable Diffusion 风格模型 `OFA-Sys/small-stable-diffusion-v0` 的

推理代码。本作业将推理所需的核心模块整理为本地代码，并在 `text_to_image.py` 中显式展示文本编码、UNet 去噪、scheduler 更新、VAE 解码以及 classifier-free guidance (CFG) 的计算过程。

CFG 简介 Classifier-free guidance 是扩散模型中常用的条件控制方法 [3]。在推理时，模型分别预测一次无条件噪声 ϵ_{uncond} 和一次文本条件噪声 ϵ_{text} ，再用 guidance scale s 放大二者之间的方向差。直观地说，较大的 s 会更强地推动生成结果符合 prompt，但也可能降低多样性，造成颜色过饱和、纹理过锐或局部伪影；较小的 s 通常生成更自由，但可能更不贴合文本。因此，CFG 是文生图推理中一个非常重要、也非常适合实验观察的超参数。

任务目标 请阅读 `text_to_image.py`、`text_to_image_utils.py` 以及本地 `diffusers/` 目录中的相关代码，理解一个文生图扩散模型在推理时如何从随机 latent 逐步生成图像。本题不要求重新训练模型，而是要求同学们理解和实验推理阶段的关键机制，特别是 CFG 对生成结果的影响。

1. **理解推理流程**：请先阅读 `text_to_image.py`，注意脚本在 CFG 部分留有 TODO。因此，在完成 CFG 之前，程序还不能生成正确的文生图结果。请结合代码说明文生图推理中以下组件分别起什么作用：

- `CLIPTokenizer` 与 `CLIPTextModel` 如何将文本提示词转换为条件表示；
- `UNet2DConditionModel` 如何根据当前 noisy latent、时间步和文本条件预测噪声；
- `DPMSolverMultistepScheduler` 如何根据噪声预测更新 latent；
- `AutoencoderKL` 如何将最终 latent 解码成 RGB 图像。

2. **完成并实验 CFG**：阅读 `text_to_image.py` 中 TODO: CFG Implementation 部分。CFG 使用无条件噪声预测 ϵ_{uncond} 和文本条件噪声预测 ϵ_{text} 合成最终噪声预测：

$$\epsilon_{\text{cfg}} = \epsilon_{\text{uncond}} + s \cdot (\epsilon_{\text{text}} - \epsilon_{\text{uncond}}),$$

其中 s 为 `guidance_scale`。请至少尝试 $s \in \{1.0, 3.0, 7.5, 12.0\}$ 四种取值，比较不同 CFG 对提示词匹配程度、图像多样性、颜色饱和度、过锐化以及伪影的影响。

3. **运行文生图模型**：完成 CFG TODO 后，运行 `text_to_image.py` 生成图像。模型文件会在首次运行时自动下载。默认使用 512×512 分辨率，请不要在报告实验中改用低分辨率。示例命令如下：

```
python text_to_image.py --prompt "an apple, 4k" --steps 15
--guidance_scale 7.5
```

本模型较小，可以在 CPU 上运行，请根据自身设备情况调整生成采样步数。更高的步数需要更多时间，可能会生成更好的样本。

4. **报告要求**：在报告中包含你使用的 prompt、随机种子、step 数和 CFG 数值；给出不同 CFG 下生成的图像；并用简短文字分析观察到的现象。

5 提交格式

- 请先删除 `*.so *.pyd` 等文件和例如 `data/` 等数据与模型，再将你的代码目录内**所有代码文件**、模型评测使用的 **checkpoint**、评测生成的**图像目录** (以 `by_class` 结尾的文件夹) 以及你的**文字报告**打包提交。统一文件的命名：`{学号}_{姓名}_hw5.zip`。
- 请将本次作业所有问题回答写在同一份报告中，报告请导出为 **pdf 格式**。

参考文献

- [1] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising Diffusion Probabilistic Models. *NeurIPS*, 2020.
- [2] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Bjorn Ommer. High-Resolution Image Synthesis with Latent Diffusion Models. *CVPR*, 2022.
- [3] Jonathan Ho and Tim Salimans. Classifier-Free Diffusion Guidance. *NeurIPS Workshop*, 2022.